

T.C. Sakarya Üniversitesi
Fen Bilimleri Enstitüsü
Bilişim Sistemleri Mühendisliği Yüksek Lisans Programı
Bilgisayar Görmesi Uygulamaları

Grad-CAM Destekli Açıklanabilir Meyve Tazelik Sınıflandırma Sistemi

A. Eren Yurtaslan - y255052061
Dersi Veren: Dr.Öğr.Üyesi SERAP ÇAKAR KAMAN

Haziran 2026, Sakarya

2. Özet

Bu çalışmada, görüntüler üzerinden sekiz meyve türünün (elma, muz, portakal, üzüm, guava, hünnap, nar, çilek) taze veya çürük durumunu ayırt eden 16 sınıflı bir derin öğrenme sistemi geliştirilmiştir. Sistem; veri hazırlama, model eğitimi, değerlendirme, açıklanabilirlik analizi ve son kullanıcı arayüzünü kapsayan uçtan uca bir bilgisayarlı görü hattı olarak tasarlanmıştır.

Veri seti, Mendeley Data üzerindeki "Fresh and Rotten Fruits Dataset" kaynağının orijinal ve artırılmış görüntülerinin tamamını içerecek şekilde genişletilmiş; toplam 21,735 eğitim ve 5,399 test görüntüsü elde edilmiştir. Eğitimde MobileNetV2 tabanlı transfer öğrenme ve iki aşamalı ince ayar (fine-tuning) uygulanmıştır. Bağımsız test kümesinde doğruluk 89.89%, makro F1 skoru 0,87; eğitim sırasında en iyi doğrulama doğruluğu 83.80% (epoch 22) olarak kaydedilmiştir.

Model kararları Grad-CAM ısı haritalarıyla görselleştirilmiş; eğitim dağılımı dışındaki girdiler için embedding uzayında cosine mesafesine dayalı üç kademeli açık küme (OOD) kararı (Bilinen / Sınırdaki / Bilinmeyen) ve temperature scaling ile güven kalibrasyonu eklenmiştir. Tüm bileşenler PyQt5 masaüstü uygulaması üzerinden son kullanıcıya sunulmaktadır.

3. Giriş

Gıda israfının önlenmesi ve kalite kontrolü, tarım, lojistik ve perakende sektörlerinde hem ekonomik hem de sürdürülebilirlik açısından kritik bir problemdir. Meyve ve sebzelerin tazeliği çoğu zaman uzman gözlemi veya basit fiziksel testlerle değerlendirilir; bu yöntemler yavaş, maliyetli ve öznel yargılara açıktır. Özellikle yüksek hacimli depo ve market ortamlarında tutarlı, ölçeklenebilir bir kalite denetimi gerekmektedir.

Son yıllarda evrimsel sinir ağları (CNN), görüntü tabanlı sınıflandırma görevlerinde insan performansına yaklaşmış veya aşmıştır. Transfer öğrenme sayesinde sınırlı etiketli veriyle bile güçlü modeller eğitmek mümkündür. Bununla birlikte derin öğrenme modelleri çoğu zaman bir "kara kutu" gibi davranır: doğru tahmin üretse bile kararın hangi görsel kanıta dayandığı açık değildir. Bu durum, güvenilirlik gerektiren gıda kalite uygulamalarında kabul edilebilirlik sorunu yaratır.

Bu proje, meyve tazeliği sınıflandırmasını Grad-CAM tabanlı açıklanabilir yapay zekâ (XAI) ile birleştiren, masaüstünde çalışan bütünleşik bir sistem sunmayı amaçlar. Kapsam; çok sınıflı tazelik tahmini, model içi kararların görselleştirilmesi, eğitim dışı nesnelerin işaretlenmesi ve tüm sürecin tek bir arayüzden yönetilmesini içerir.

4. Problem Tanımı

Çalışmanın temel problemi, tek bir RGB meyve görüntüsünün girdi olarak alınması ve 16 kapalı küme sınıfından birine atanmasıdır. Her meyve türü için taze ve çürük durum ayrı sınıflar olarak modellenmiştir: freshapples, rottenapples, freshbanana, rottenbanana, freshoranges, rottenoranges, freshgrapes, rottengapes, freshguava, rottenguava, freshjujube, rottenjujube, freshpomegranate, rottenpomegranate, freshstrawberry ve rottenstrawberry.

Girdi: 224×224 piksel boyutuna ölçeklenmiş ve normalize edilmiş renkli görüntü. Çıktı: en olası sınıf etiketi, sınıfa ait güven skoru, tüm sınıflar için olasılık dağılımı, OOD durumu (Bilinen / Sınırdaki / Bilinmeyen) ve isteğe bağlı Grad-CAM ısı haritası. Eğitimde yer almayan veya görsel olarak belirgin şekilde farklı nesneler (ejder meyvesi, mandalina, mürdüm eriği vb.) yanlışlıkla yüksek güvenle bilinen sınıfa atanmamalı; uygun durumlarda Sınırdaki veya Bilinmeyen etiketi üretilmelidir.

Başarı ölçütleri şunlardır: (1) bağımsız test kümesinde yüksek sınıflandırma doğruluğu ve dengeli F1 skorları; (2) Grad-CAM haritalarında kararın meyve yüzeyindeki bozulma, renk veya doku değişimlerine odaklanması; (3) yedi dış meyve örneğinde en az 5/7 oranında OOD işaretlemesi; (4) veri seti görüntülerinin OOD uyarısı almadan doğru sınıflandırılması. Fonksiyonel gereksinim olarak model tahmininin tek tıkla çalışan, kaydırılabilir bir masaüstü arayüzden sunulması hedeflenmiştir.

5. Veri Seti

Veri seti 16 sınıf içermekte olup dataset/train ve dataset/test altında sınıf başına ayrı klasörlerle tutulur. Klasör adları doğrudan model etiketlerine dönüştürülür; böylece yeni sınıf eklendiğinde kod değişikliği gerektirmeden ölçeklenebilir bir yapı korunur.

Ana kaynak, Mendeley Data üzerindeki "Fresh and Rotten Fruits Dataset" (DOI: 10.17632/bdd69gyhv8.1, CC BY 4.0) olup orijinal fotoğraflar ile "Augmented Image" alt klasöründeki döndürme, çevirme, yakınlaştırma ve öteleme gibi dönüşümlerden üretilmiş artırılmış görüntülerin tamamı sekiz meyve türü için entegre edilmiştir. Her tür için taze ve çürük ayrı sınıf klasörlerindedir; örneğin üzüm için freshgrapes ve rottengapes.

Veri sızıntısı önlenmiştir: Mendeley orijinaleri sınıf bazında %80 eğitim / %20 test olarak bölünmüş, dosya adlarına mendeley_ öneki eklenmiştir. Eğitim kümesinden %20 doğrulama (validation) ayrılmış; test kümesi yalnızca nihai değerlendirmede kullanılmıştır. Güncel toplam: 21,735 eğitim ve 5,399 test görüntüsü. Sınıflar arası örnek sayısı dengesizdir (örneğin elma ve muz sınıfları üzüm veya nar sınıflarından çok daha kalabalıktır); bu nedenle eğitimde sklearn tabanlı class_weight ile ağırlıklandırma uygulanmıştır.

Açık küme doğrulaması için iki ek küme tutulur: outputs/ood_eval altında her sınıftan holdout örnekleri (eğitimdeki sınıf adlarıyla aynı klasör yapısı); outputs/ood_test altında yedi gerçek dünya dışı meyve görüntüsü (ejder meyvesi, greyfurt, liçi, mandalina, mor erik, mor üzüm, mürdüm eriği). Aşağıdaki tablo sınıf bazında eğitim ve test dağılımını özetler.

Sınıf	Eğitim	Test
freshapples	2441	581
freshbanana	2333	569
freshgrapes	640	160
freshguava	638	159
freshjube	635	158
freshoranges	2263	587
freshpomegranate	638	159
freshstrawberry	590	147
rottenapples	3093	788
rottenbanana	2973	717
rottengapes	597	149
rottenguava	638	159
rottenjube	635	158
rottenoranges	2392	602
rottenpomegranate	639	159
rottenstrawberry	590	147

Toplam	21735	5399
--------	-------	------

6. Kullanılan Teknolojiler

Proje Python 3.9 ortamında geliştirilmiştir. Derin öğrenme çerçevesi olarak TensorFlow 2.x ve üst düzey Keras API kullanılmıştır. Model eğitimi, değerlendirme ve çıkarım (inference) aynı çatı altında yürütülerek tekrarlanabilirlik sağlanmıştır.

Görüntü okuma ve ön işleme için OpenCV ve Pillow; sayısal hesaplar için NumPy; eğitim eğrileri, karmaşıklık matrisi ve Grad-CAM görselleştirmesi için Matplotlib; sınıflandırma metrikleri ve class_weight hesabı için Scikit-Learn tercih edilmiştir. Son kullanıcı arayüzü PyQt5 ile oluşturulmuş; akademik PDF raporu ReportLab kütüphanesiyle üretilmiştir.

Proje yapısı modülerdir: src/config.py merkezi ayarları, src/data_loader.py veri akışını, src/model_builder.py mimariyi, utils/predictor.py tahmin ve OOD mantığını, ui/main_window.py arayüzü yönetir. Eğitim (train.py), değerlendirme (evaluate.py), Grad-CAM (gradcam.py), OOD kalibrasyonu (calibrate_ood.py) ve rapor üretimi (generate_report.py) bağımsız betikler olarak çalıştırılabilir. Model ağırlıkları models/fruit_model.h5 dosyasında saklanır.

7. Yöntem

Yöntem, ImageNet üzerinde önceden eğitilmiş MobileNetV2 tabanlı transfer öğrenmeyi temel alır. Mimari akışı şöyledir: Giriş ($224 \times 224 \times 3$) → isteğe bağlı hafif veri artırma → MobileNetV2 özellik çıkarıcı → GlobalAveragePooling2D → Dropout (0,3) → Dense softmax çıkış katmanı. Veri seti zaten Mendeley tarafından artırıldığından eğitimde agresif dönüşümlerden kaçınılmış; yatay çevirme, $\pm 10^\circ$ döndürme, yakınlaştırma ve kontrast değişimi gibi hafif artırma katmanları kullanılmıştır.

Eğitim iki aşamalı yürütülmüştür. Birinci aşamada (özellik çıkarımı) MobileNetV2 tabanı donuk tutulmuş, yalnızca yeni sınıflandırma başlığı Adam optimizasyonu (öğrenme oranı $1e-3$) ile eğitilmiştir; EarlyStopping doğrulama kaybını izleyerek 12. epoch'ta durmuştur. İkinci aşamada (ince ayar) tabanın son 30 katmanı açılmış, öğrenme oranı $1e-5$ 'e düşürülerek 10 epoch ince ayar yapılmıştır. Toplam 22 epoch sonunda en iyi doğrulama doğruluğu 83.80% (epoch 22) olarak kaydedilmiştir.

Değerlendirme aşamasında model, önceden ayrılmış bağımsız test kümesi üzerinde çalıştırılmış; doğruluk, precision, recall, F1 ve karmaşıklık matrisi üretilmiştir. Tahmin aşamasında görüntü aynı ön işleme hattından geçirilir; softmax çıkışı temperature scaling ($T=1.45$) ile kalibre edilir. GlobalAveragePooling katmanından elde edilen embedding vektörü, eğitim kümesinden hesaplanan sınıf merkezlerine cosine mesafesi ile karşılaştırılarak üç kademeli OOD kararı verilir. Grad-CAM, hedef sınıfa göre son konvolüsyon katmanındaki gradyanları kullanarak kararın görsel kanıtını üretir.

8. MobileNetV2 Mimarisi

MobileNetV2, Sandler ve arkadaşları tarafından önerilen, mobil ve gömülü cihazlar için tasarlanmış hafif bir evrişimli sinir ağı mimarisidir. Temel yapı taşı derinlemesine ayrılabilir konvolüsyon (depthwise separable convolution) olup standart konvolüsyona kıyasla hem hesaplama hem de bellek maliyetini önemli ölçüde azaltır. Ters artık (inverted residual) bloklar ve doğrusal darboğazlar (linear bottlenecks) bilgi kaybını sınırlarken temsil gücünü korur.

Bu projede include_top=False ile ImageNet ağırlıkları yüklenmiş; orijinal 1000 sınıflı çıkış katmanı atılarak meyve tazeliği için yeni bir softmax başlığı eklenmiştir. Giriş çözünürlüğü 224×224 pikseldir; bu boyut MobileNetV2'nin ImageNet ön-eğitim ayarıyla uyumludur. Ön işleme olarak tf.keras.applications.mobilenet_v2.preprocess_input kullanılmıştır; bu, piksel değerlerini [-1, 1] aralığına ölçekler.

MobileNetV2'nin bu çalışmada seçilme gerekçeleri şunlardır: (1) sınırlı donanımda makul çıkarım süresi; (2) transfer öğrenme ile küçük ve orta ölçekli veri setlerinde güçlü özellik çıkarımı; (3) Grad-CAM için erişilebilir ara katmanlar; (4) PyQt5 masaüstü uygulamasında tek seferlik model yükleme sonrası hızlı tahmin. Alternatif ağlar (ResNet50, EfficientNet) daha yüksek doğruluk potansiyeli sunsa da hesaplama maliyeti ve proje kapsamı göz önünde bulundurularak MobileNetV2 tercih edilmiştir.



9. Eğitim Süreci

Model eğitimi train.py betiği ile yürütülmüştür. Eğitim kümesi (21,735 görüntü) içinden %20 oranında doğrulama alt kümesi ayrılmış; bağımsız test kümesi (5,399 görüntü) eğitim boyunca hiç kullanılmamıştır. Yığın boyutu 32, rastgelelik tohumu 42 olarak sabitlenmiş; böylece deneyler tekrarlanabilir kılınmıştır. Sınıf dengesizliği sklearn compute_class_weight ile hesaplanan ağırlıklarla her iki aşamada da telafi edilmiştir.

Birinci aşama (özellik çıkarımı): MobileNetV2 tabanı donuk tutulmuş, yalnızca GlobalAveragePooling → Dropout → Dense başlığı eğitilmiştir. Adam optimizasyonu, öğrenme oranı 0.001, kayıp fonksiyonu sparse categorical crossentropy, en fazla 20 epoch. EarlyStopping (izlenen: val_loss, sabır: 5) 12. epoch'ta eğitimi durdurmuştur. Bu aşamada doğrulama doğruluğu yaklaşık %81'e ulaşmıştır.

İkinci aşama (ince ayar): Tabanın son 30 katmanı eğitilebilir yapılmış, öğrenme oranı 1e-05'e düşürülmüştür (önceden öğrenilen düşük seviye filtreleri bozmamak için). 10 epoch ince ayar sonrası toplam 22 epoch tamamlanmış; en iyi doğrulama doğruluğu 83.80% (epoch 22), son epoch eğitim doğruluğu yaklaşık %97,6'dır. ModelCheckpoint (izlenen: val_accuracy) en iyi ağırlıkları models/fruit_model.h5 dosyasına kaydetmiştir. İnce ayar başlangıcında doğrulama kaybında kısa süreli artış görülmüş; bu, taban katmanlarının yeniden uyarlanmasıyla kaynaklanan beklenen bir geçiş etkisidir.

Aşağıdaki grafikler eğitim ve doğrulama doğruluğu ile kayıp eğrilerini göstermektedir. Eğitim doğruluğunun doğrulama doğruluğunun üzerinde seyretmesi hafif aşırı öğrenme eğilimine işaret eder; EarlyStopping ve Dropout bu etkiyi sınırlamıştır. Dikey kesik çizgi birinci ve ikinci aşama geçişini işaretler.



10. Performans Sonuçları

Nihai değerlendirme evaluate.py ile bağımsız test kümesi üzerinde yapılmıştır. Test seti 5,399 görüntü ve 16 sınıf içerir; her sınıfın örnek sayısı farklıdır (örneğin freshapples 581, rottengapes 149). Metrikler çok sınıflı sınıflandırma için makro ve ağırlıklı ortalama olarak raporlanmıştır: makro ortalama tüm sınıflara eşit ağırlık verirken, ağırlıklı ortalama örnek sayısına göre ağırlıklandırır.

Precision (kesinlik), pozitif tahminlerin ne kadarının doğru olduğunu; Recall (duyarlılık), gerçek pozitiflerin ne kadarının yakalandığını ölçer. F1 skoru bu iki metriğin harmonik ortalamasıdır. Gıda kalite uygulamalarında çürük meyvenin taze olarak etiketlenmesi (düşük recall) genellikle taze

meyvenin çürük sayılmasından (düşük precision) daha riskli kabul edilir; bu nedenle zayıf recall gösteren sınıflar özellikle dikkatle incelenmiştir.

Metrik	Deger
Dogruluk (Accuracy)	89.89%
Precision (Makro)	90.50%
Recall (Makro)	87.22%
F1 Skoru (Makro)	87.44%
Precision (Agirlikli)	91.21%
Recall (Agirlikli)	89.89%
F1 Skoru (Agirlikli)	89.71%

Genel test doğruluğu 89.89%'dir. Makro precision %90,5; makro recall %87,2; makro F1 0,87 olarak hesaplanmıştır. Ağırlıklı F1 0,90 değeri, yüksek örnek sayılı sınıflarda (elma, muz, portakal) güçlü performansın genel ortalamayı yukarı çektiğini gösterir.

Sınıf bazlı performans tablosu aşağıdadır. En güçlü sınıflar: freshbanana (recall %100, F1 0,95), freshapples (recall %100), rottenbanana (precision %100, F1 0,96) ve freshstrawberry (F1 0,95). En zayıf sınıflar: çürük üzüm (rottengapes, recall yaklaşık %43, F1 0,60), çürük hünnap (rottenjujube, recall %69) ve çürük nar (rottenpomegranate, recall %72). rottengapes için yüksek precision (%100) ancak düşük recall, modelin çürük üzüm tahmin ettiğinde çoğunlukla doğru olduğunu fakat çürük üzümlerin önemli bir kısmını başka sınıflara (özellikle freshgrapes) atadığını gösterir.


Sınıf	Precision	Recall	F1	N
freshapples	78.0%	100.0%	88.0%	581
freshbanana	91.0%	100.0%	95.0%	569
freshgrapes	66.0%	100.0%	79.0%	160
freshguava	99.0%	92.0%	95.0%	159
freshjujube	76.0%	99.0%	86.0%	158
freshoranges	89.0%	95.0%	92.0%	587
freshpomegranate	91.0%	81.0%	86.0%	159
freshstrawberry	95.0%	94.0%	95.0%	147
rottenapples	94.0%	85.0%	89.0%	788
rottenbanana	100.0%	92.0%	96.0%	717
rottengapes	100.0%	43.0%	60.0%	149
rottenguava	91.0%	94.0%	92.0%	159
rottenjujube	95.0%	69.0%	80.0%	158
rottenoranges	94.0%	86.0%	90.0%	602
rottenpomegranate	94.0%	72.0%	82.0%	159
rottenstrawberry	94.0%	95.0%	94.0%	147

11. Karmaşıklık Matrisi

Karmaşıklık matrisi (confusion matrix), 16×16 boyutunda olup her hücre gerçek sınıf (satır) ile tahmin edilen sınıf (sütun) arasındaki örnek sayısını gösterir. Köşegen hücreler doğru sınıflandırmaları, köşegen dışı hücreler ise hataları temsil eder. Matris evaluate.py tarafından üretilmiş ve outputs/confusion_matrix.png olarak kaydedilmiştir.

Matrisin genel yapısı, modelin büyük sınıflarda (elma, muz, portakal) güçlü köşegen değerleri ürettiğini; ancak üzüm ve hünnap çiftlerinde taze/çürük karışıklığı görüldüğünü ortaya koyar. rottengapes satırında taze üzüme (freshgrapes) kayan tahminler recall düşüklüğünün ana kaynağıdır. Benzer şekilde rottenjuube ile freshjuube, rottenpomegranate ile freshpomegranate arasında görsel benzerlik nedeniyle çapraz hatalar gözlenir. Çürük portakal (rottenoranges) ve taze portakal (freshoranges) karışıklığı nispeten düşük düzeydedir.

16 sınıflı matris okunabilirlik için renk yoğunluğu ile görselleştirilmiştir. Akademik değerlendirmede matris, yalnızca genel doğruluk yüzdesinin ötesinde hangi sınıf çiftlerinin iyileştirme gerektirdiğini somutlaştırır; bu bulgular Bölüm 15'teki gelecek çalışma önerileriyle doğrudan ilişkilidir.




12. Grad-CAM Analizi

Grad-CAM (Gradient-weighted Class Activation Mapping), Selvaraju ve arkadaşları tarafından önerilen ve derin sinir ağlarının kararlarını görselleştirmek için yaygın kullanılan bir açıklanabilir yapay zekâ (XAI) yöntemidir. Temel fikir, hedef sınıfa ait çıkış skorunun son konvolüsyon katmanındaki aktivasyonlara göre gradyanını almak ve bu gradyanları kanal ağırlıkları olarak kullanmaktır. Ağırlıklı kanal toplamı ReLU ile pozitifleştirilerek ısı haritası üretilir; harita orijinal görüntü boyutuna yeniden ölçeklenir.

Bu projede Grad-CAM uygulaması gradcam.py betiği ve PyQt5 arayüzünün Grad-CAM sekmesi üzerinden sunulur. Son konvolüsyon katmanı MobileNetV2 tabanı içinde otomatik tespit edilir; veri artırma katmanı atlanarak yalnızca Conv2D içeren iç model seçilir. Isı haritası orijinal görüntüye 0.4

alfa değeriyle bindirilir (overlay): kırmızı/sıcak bölgeler tahmine en çok katkı veren pikselleri, soğuk bölgeler ise düşük etkili alanları gösterir.

Çürük portakal ve çürük üzüm örneklerinde ısı haritaları, modelin kararını çoğunlukla meyve yüzeyindeki renk değişimi, leke veya doku bozulması üzerinde yoğunlaştırdığını göstermiştir. Arka plan veya tabak gibi alakasız bölgelere yapılan yanlış odaklanma gözlemlenmemiştir; bu da modelin anlamlı görsel kanıta dayandığını destekler. Arayüzde kullanıcı, analiz edilen görsel için tahmin edilen sınıfın Grad-CAM haritasını yan yana orijinal görüntü ile inceleyebilir; hedef katman adı teknik açıklama kutusunda gösterilir.



12.1 Açık Küme Tanıma (Open-Set Recognition) Bulguları

Kapalı küme (closed-set) sınıflandırıcılar, her girdiyi eğitimde görülen sınıflardan birine atamak zorundadır. Gerçek dünyada ise kamera önüne eğitimde yer almayan meyveler veya farklı türler gelebilir; yüksek softmax güveni bu durumda yanıltıcı olabilir. Bu nedenle sisteme, GlobalAveragePooling katmanından elde edilen embedding vektörlerine dayalı açık küme

(out-of-distribution, OOD) tespiti eklenmiştir. Eğitim kümesinden sınıf başına en fazla 400 örnek kullanılarak sınıf merkezleri hesaplanmış; test girdisinin merkeze cosine mesafesi karar için temel sinyal olarak alınmıştır.

Karar mekanizması üç kademelidir ve mesafe önceliklidir: (1) mesafe > T_yüksek (0.485) → koşulsuz "Bilinmeyen" (softmax güveni bu kararı ezemez); (2) mesafe < T_düşük (0.365) → "Bilinen"; (3) gri bölgede softmax tahmini ile en yakın embedding merkezinin sınıfı uyuşuyorsa "Sınırdaki" (düşük güven uyarısı ve Belirsiz etiketler), uyuşmuyorsa "Bilinmeyen". Gri bölge için ek olarak maksimum olasılık eşiği (0.8) ve entropi eşiği (0.3) kullanılır.

Güven yüzdesi, temperature scaling ile ayrıca kalibre edilmiştir ($T=1.45$). Bu işlem beklenen kalibrasyon hatasını (ECE) 0,065'ten 0,022'ye düşürmüştür; argmax tahminleri değişmemiştir. OOD eşikleri 1344 bilinen test örneği, 7 dış meyve görüntüsü ve 200 holdout örneği üzerinde ızgaralı arama ile seçilmiştir: bilinen örneklerde yanlış bilinmeyen oranı $\leq 2\%$, dış örneklerde işaretleme $\geq 5/7$, holdout'ta yanlış bilinmeyen $\leq 10\%$.

Yedi dış örnek (outputs/ood_test) sonuçları: mürdüm eriği Bilinmeyen olarak işaretlenmiştir; ejder meyvesi, greyfurt, liçi ve mor erik Sınırdaki uyarısı almıştır; mandalina Bilinen (Fresh Orange) kabul edilmiştir; mor üzüm Sınırdaki (Rotten Strawberry tahminiyle). Toplam işaretleme 6/7'dir. ood_eval holdout kümesinde (her sınıftan 10'ar görüntü, taze/çürük ayrı klasörler) 100 örneğin tamamı Bilinen olarak tanınmıştır. dataset/ altındaki eğitim ve test görüntüleri, eğitim dağılımının parçası oldukları için OOD katmanından bilinçli olarak muaf tutulur; böylece veri seti örneklerinde "yüksek güven + sınırdaki uyarısı" çelişkisi önlenir.

13. PyQt5 Uygulaması

Son kullanıcıya yönelik masaüstü uygulaması PyQt5 ile geliştirilmiştir (app.py). Sol panelde görsel seçme, önizleme ve "Analiz Et" düğmesi; sağ panelde dört sekme bulunur. Model uygulama açılışında bir kez belleğe yüklenir; her analiz yalnızca çıkarım (inference) çalıştırır ve arayüz donmasını önlemek için ağır işlemler ana iş parçacığında kısa sürede tamamlanacak şekilde tasarlanmıştır.

Analiz sekmesi üç bölümden oluşur: Sonuç Özeti (tahmin edilen sınıf, kalite durumu, meyve türü, ham sınıf adı ve güven skoru); Dağılım ve OOD Kararı (Bilinen / Sınırdaki / Bilinmeyen durumu, OOD mesafesi, entropi ve tetikleyen kural); Sınıf Olasılıkları (16 sınıf için kaydırılabilir olasılık çubukları). OOD durumuna göre renk kodlaması uygulanır: bilinen yeşil, sınırdaki turuncu, bilinmeyen kırmızı.

Grad-CAM sekmesi orijinal görüntü ile ısı haritasını yan yana gösterir; hedef katman adı ve kısa teknik açıklama sunulur. Model Bilgileri sekmesi mimari özet, sınıf listesi, eğitim geçmişi ve kalibrasyon parametrelerini beş kart halinde listeler. Performans Sonuçları sekmesi test doğruluğu, makro/ağırlıklı F1 değerlerini özet kartında gösterir; doğruluk/kayıp eğrileri, karmaşıklık matrisi ve sınıf bazlı metrik grafikleri tıklanarak büyütülebilir. Tüm sekmeler küçük ekranlarda QScrollArea ile kaydırılabilir. Eğitim logunun canlı izlenmesi için watch_training.py --follow betiği sağlanmıştır.

14. Sonuçlar

Bu çalışmada sekiz meyve türü için taze/çürük ayrımını 16 ayrı sınıf altında ele alan, açıklanabilir ve açık küme destekli bir meyve tazelik sınıflandırma sistemi başarıyla tamamlanmıştır. Mendeley veri setinin orijinal ve artırılmış görüntülerinin tam entegrasyonu sonucunda 21,735 eğitim ve 5,399 test görüntüsünden oluşan ölçeklenebilir bir veri hattı kurulmuştur.

MobileNetV2 tabanlı transfer öğrenme ile eğitilen model, bağımsız test kümesinde 89.89% doğruluk, makro F1 0,87 ve ağırlıklı F1 0,90 değerlerine ulaşmıştır. Eğitim sırasında kaydedilen en iyi doğrulama doğruluğu 83.80% (epoch 22)'dir. En güçlü sınıflar taze muz (recall %100) ve çürük muz (F1 0,96) iken en zayıf sınıf çürük üzüm (rottengapes, recall yaklaşık %43) olarak öne çıkmıştır; bu durum sınıf dengesizliği ve görsel benzerlikten kaynaklanmaktadır.

Grad-CAM analizleri, model kararlarının çoğunlukla meyve yüzeyindeki anlamlı bölgelere dayandığını göstermiştir. Üç kademeli OOD mekanizması yedi dış meyve örneğinin 6'sını uygun şekilde işaretlemiş; holdout kümesinde %100 tanıma sağlamıştır. Temperature scaling güven kalibrasyonunu iyileştirmiş, veri seti örnekleri için OOD bypass mantıksal tutarlılığı korumuştur. PyQt5 uygulaması tahmin, açıklama, model bilgisi ve performans raporlamasını tek bir arayüzde birleştirerek projeyi akademik rapordan öte kullanılabilir bir ürüne dönüştürmüştür.

15. Gelecek Çalışmalar

Sınıf bazlı performans farkları, özellikle çürük üzüm ve çürük nar gibi düşük recall gösteren sınıflar için hedefli veri toplama, sentetik artırım ve focal loss gibi dengesiz veri stratejilerinin denenmesini gerektirir. Mendeley dışı gerçek dünya görüntüleri (farklı aydınlatma, kamera, arka plan) ile genelleme testleri yapılmalıdır.

Model mimarisi açısından EfficientNet-B0, ConvNeXt veya küçük Vision Transformer modelleriyle doğruluk/hız dengesi karşılaştırılabilir. TensorFlow Lite veya ONNX dönüşümü ile mobil ve gömülü cihazlarda gerçek zamanlı çıkarım hedeflenebilir. OOD tarafında sınıf-bazlı mesafe eşikleri, Mahalanobis mesafesi, OpenMax veya ArcFace benzeri metrik öğrenme yöntemleri; mandalina gibi sınır vakalar ile mürdüm eriği gibi kesin bilinmeyen örnekleri aynı anda iyileştirmeyi amaçlayan hibrit karar modelleri değerlendirilebilir.

Arayüz geliştirmeleri arasında toplu görüntü analizi, sonuçların CSV/PDF olarak dışa aktarımı ve kamera akışından canlı tahmin yer alabilir. Son olarak, Grad-CAM++ veya SHAP gibi alternatif açıklama yöntemlerinin karşılaştırmalı bir kullanılabilirlik çalışması, sistemin güvenilirlik algısını güçlendirebilir.

16. Kaynakça

1. Sandler, M., Howard, A., Zhu, M., Zhmoginov, A. ve Chen, L. C. (2018). MobileNetV2: Inverted Residuals and Linear Bottlenecks. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), ss. 4510–4519.
2. Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D. ve Batra, D. (2017). Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization. Proceedings of the IEEE International Conference on Computer Vision (ICCV), ss. 618–626.
3. Mendeley Data (2020). Fresh and Rotten Fruits Dataset. DOI: 10.17632/bdd69gyhv8.1 (CC BY 4.0).
4. Guo, C., Pleiss, G., Sun, Y. ve Weinberger, K. Q. (2017). On Calibration of Modern Neural Networks. International Conference on Machine Learning (ICML).
5. Bendale, A. ve Boulton, T. (2016). Towards Open Set Deep Networks. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR).
6. Chollet, F. ve diğerleri. TensorFlow ve Keras resmi dokümantasyonu. <https://www.tensorflow.org>
7. Pedregosa, F. ve ark. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, ss. 2825–2830.
8. The Qt Company. PyQt5 Reference Documentation, <https://www.riverbankcomputing.com/static/Docs/PyQt5/>